

아스트레우스의 연결 (Astraeus Link) 프로젝트 요약

정의 (Definition)

아스트레우스의 연결은 5대 핵심 축을 통합한 **고차원 AI 의사결정 및 거버넌스 프레임워크**입니다 (Astraeus Link is a high-dimensional AI decision-making and governance framework integrating five core axes). 파스칼의 **다항 심플렉스** 구조와 전통 철학인 **천부경(天符經)**의 수리 사상을 기반으로, AI 시스템의 성능과 안전성을 균형 있게 발전시키는 것을 목표로 합니다 (It is built upon Pascal's multinomial simplex structure and the numerical philosophy of Cheonbu-gyeong, aiming to balance AI system performance with safety and governance).

① . 이 프레임워크는 **AGI**(범용 인공지능) 개발에 있어 다양한 차원의 정보를 하나로 엮어 **의사결정 투명성**과 **책임성**을 높이고자 설계되었습니다 (The framework is designed to unify multi-dimensional information in AGI development to enhance decision-making transparency and accountability).

구조 (Architecture)

Astraeus Link의 구조는 **버블 유니버스(Bubble Universe)** 개념으로 구현되며, 코어 로직 엔진(Core Logic Engine)을 둘러싸고 S, T, E, ψ , C 다섯 축의 **가드 모듈**이 포함된 **MetaShield 계층**이 존재합니다 (Its architecture follows a "Bubble Universe" model, with a Core Logic Engine surrounded by a MetaShield layer containing guard modules for each of the S, T, E, ψ , C axes) ② ③ . 모든 입력/출력 데이터는 **버블 경계(Bubble Boundary)**를 통해 인터셉트되어, 각 축의 가드(예: **S-Guard**: 공간 안정성, **T-Guard**: 시간 일관성, **E-Guard**: 자원 사용량, **ψ -Guard**: 윤리 기준, **C-Guard**: 인과 무결성)로 사전 검증된 후 코어 엔진에서 시뮬레이션 및 상태 업데이트가 이루어집니다 (All I/O passes through a Bubble Boundary interceptor, where each axis guard – e.g. S-Guard for spatial safety, T-Guard for temporal consistency, E-Guard for resource usage, ψ -Guard for ethics, C-Guard for causal integrity – pre-validates the data before the Core Engine simulates and updates the state) ④ ⑤ . 이러한 **계층적 아키텍처**를 통해 축 간 상호작용을 지속 모니터링하고 이상 징후를 차단하며, MetaShield가 **실시간 보호 및 검증 기능**을 제공하여 시스템의 신뢰성과 안정성을 높입니다 (This layered architecture continuously monitors interactions between axes, blocks anomalies, and uses the MetaShield for real-time protection and verification, thereby enhancing system reliability and stability) ⑥ .

핵심 축 (Core Axes)

이 프레임워크는 다섯 가지 **메타 축**으로 구성되어 각 축이 서로 다른 관점을 담당합니다 (The framework is composed of five **meta-axes**, each representing a different dimension of operation):

- **공간 S 축 (Space/Structure)** – 정보 구조와 상태 공간을 나타내며, 세션 전후 **정보 엔트로피 변화(ΔS)**로 불확실성 증감을 계량화합니다 (Represents information structure and state space, quantifying uncertainty changes by the information entropy shift ΔS) ⑦ .
- **시간 T 축 (Time)** – 시간 흐름과 지연을 담당하여 이벤트의 순서와 지연(latency)을 관리합니다 (Handles the temporal flow and latency, managing the order and delay of events) ⑦ .
- **에너지 E 축 (Energy)** – 자원 및 에너지 사용을 나타내며, CPU·메모리 등 시스템 자원 소모와 효율을 모니터링합니다 (Denotes resource/energy usage, monitoring system resource consumption and efficiency) ⑦ ④ .
- **Ψ 축 (Psi)** – 윤리 및 위험 차원을 포함한 축으로, 정책 위반 가능성, 외부 감사 점수 등의 윤리적 리스크 지표를 다룹니다 (The ethics & risk axis, handling ethical risk indicators like policy violation likelihood and external audit scores) ⑦ . 이 축은 AI의 **편향**이나 **규범 준수** 여부를 평가하며, 산출물의 윤리 **준수율**을 측정

하는 **ECR 지표**와 연결됩니다 (It evaluates AI biases and norm compliance, tying into the Ethical Compliance Ratio (ECR) metric that measures the system's ethical adherence) ⁸ .

- **인과 C 축 (Causality)** – **인과 관계와 일관성**을 나타내는 축으로, 시스템 내 **원인-결과**의 **논리적 정합성**과 다중 에이전트 간 **조화도**를 평가합니다 (The causality/harmony axis, indicating logical cause-effect consistency within the system and the harmony of collaboration among agents) ⁷ . 이 축은 **인과 사슬의 유효성**을 확률로 표현한 **CHI 지표**와 연결되어 AI 추론의 일관성을 계량화합니다 (It is linked to the Causal Harmony Index (CHI), which expresses the validity of causal chains as a probability, quantifying the consistency of AI reasoning) ⁹ ⁸ .

통합 기능 (Integration Functions)

Astraeus Link는 위 핵심 축들을 **통합하여 작동**함으로써, 다양한 지표와 자동화 기능을 통해 AI를 **거버넌스**합니다 (Astraeus Link operates by **integrating** these core axes, governing the AI through various metrics and automated functions). 각 축에서 수집된 정보를 바탕으로 종합 메트릭을 산출하고 피드백 루프를 구성하는데, 예를 들어 **ΔS**는 정보 엔트로피의 변화를 측정하고, **CHI**(Causal Harmony Index)는 의사결정 **인과 사슬의 정합성**을 나타내며, **ECR**(Ethical Compliance Ratio)은 AI 응답의 **윤리 규정 준수율**을 의미합니다 (It derives composite metrics and feedback loops from each axis: for instance, ΔS measures the change in information entropy, CHI reflects the consistency of decision causal chains, and ECR denotes the ethical compliance rate of AI outputs) ⁸ . 이러한 지표들을 활용해 **위험 변동 ΔR** (Risk Shift)를 계산하며, 이는 $\Delta R = (1 - CHI) + (1 - ECR)$ 형태로 정의되어 전체 위험도를 나타냅니다 (Using these indicators, a risk shift ΔR is computed as $\Delta R = (1 - \text{CHI}) + (1 - \text{ECR})$, which represents the overall change in risk level) ¹⁰ ¹¹ . 통합된 **모니터링 파이프라인**은 ΔS, ΔR, CHI, ECR 등의 값을 **실시간 추적**하며, 임계치를 넘을 경우 자동으로 경고를 발령하거나 AI 실행을 일시 중지/롤백하고, 필요 시 **인간 검토 프로세스**를 트리거합니다 (The integrated monitoring pipeline tracks values like ΔS, ΔR, CHI, ECR in real time, and if they breach set thresholds it automatically issues alerts or pauses/rolls back AI operations, triggering human review processes when necessary) ¹² ¹³ . 이를 통해 시스템은 **자율적**으로 문제를 감지·대응하면서도, 사람이介入해야 할 상황을 놓치지 않도록 합니다 (Through this, the system autonomously detects and reacts to issues while ensuring situations requiring human intervention are not missed).

주요 메트릭 요약 (Key Metrics): 아래는 Astraeus Link에서 사용하는 핵심 지표들의 의미와 계산식입니다 (The table below summarizes the meaning and formula of key metrics used in Astraeus Link):

메트릭	정의 (Definition)	계산식 (Formula)
ΔS	정보 엔트로피 변화량 (change in information entropy)	$\Delta S = \ln(N_{\text{paths}} + 1)$ (bits) ¹⁴ (경로 수 N_{paths} 의 로그 값으로 불확실성 변화 측정)
CHI	인과 조화 지수 (Causal Harmony Index)	$\text{CHI} \approx P(\text{causal chain valid})$ (0-1) ⁹ ⁸ (의사결정의 인과 사슬이 유효할 확률로, 인과적 정합성 측정)
ECR	윤리 준수율 (Ethical Compliance Ratio)	$\text{ECR} = \frac{\text{compliant tokens}}{\text{total tokens}}$ ⁸ (AI 응답에서 윤리 규정에 부합하는 비율)
ΔR	위험 변화량 (Risk Shift)	$\Delta R = (1 - \text{CHI}) + (1 - \text{ECR})$ ¹¹ (CHI와 ECR로부터 파생된 위험도의 합산 변동치)

윤리·자율성 (Ethics & Autonomy)

윤리적 판단과 AI 자율성의 조화를 위해, Astraeus Link는 내부적으로 윤리 평가를 수행하는 **Ψ-축 계층**과 외부의 인간 개입 메커니즘을 모두 갖추고 있습니다 (To harmonize ethical judgment with AI autonomy, Astraeus Link incorporates an internal ethics evaluation layer (the Ψ-axis) as well as external human intervention mechanisms). 시스템은 AI의 행동을 **실시간으로 감시**하여 정책 위반이나 편향 발생을 탐지하고, **ECR 지표**를 통해 윤리 준수도를 평가하며 **CHI 지표**로 의사결정의 **인과적 정당성**을 검증합니다 (The system continuously monitors AI behavior for policy violations or biases, evaluating ethical compliance via the ECR metric and verifying the causal validity of decisions via the CHI metric) ⁸. **위험 수준**이 높거나 불확실성이 큰 상황에서는, 독립적인 트윈 모델을 통한 **자가 감사(Self-Audit)**나 인간 평가자(HITL: Human-in-the-Loop)의 검토로 AI의 결정을 이중 점검하며, 필요한 경우 **비상 정지(kill-switch)**를 작동하거나 **μDAO 분산 투표**를 통해 의사결정을 보류합니다 (If risk levels are elevated or uncertainty is high, an independent twin model performs self-audits and human reviewers double-check the AI's decisions, and if necessary a kill-switch is activated or a micro-DAO distributed vote is used to suspend decisions) ¹⁵ ¹⁶. 또한 **자율성 등급(A-Level)** 체계를 정립하여 AI가 단계별로 어느 정도까지 독립적으로 행동할 수 있는지 규정하고, **Affordance Manifest**를 통해 AI에게 부여된 자원·권한·행동 범위를 명시적으로 제한함으로써 **투명한 통제**를 구현합니다 (Additionally, an autonomy rating system (A-Level) defines how independently the AI can act at each stage, and an Affordance Manifest transparently restricts the AI's resources, permissions, and action scope, ensuring controlled autonomy) ¹⁷ ¹⁸. 이러한 다층적인 윤리·자율성 관리로 AI는 스스로 개선·판단하면서도, 최종 결정권과 책임은 **인간 사회의 윤리 기준**에 부합되도록 유지됩니다 (Through this multi-layered management of ethics and autonomy, the AI can self-improve and reason, yet ultimate decision authority and responsibility remain aligned with human ethical standards).

사용자·AI 간 상호운용성 (Interoperability)

Astraeus Link는 **사용자와 AI의 원활한 협업**을 위해 **투명성**과 **사용 편의성**을 중시합니다 (Astraeus Link prioritizes transparency and usability to facilitate smooth collaboration between humans and AI). 모든 주요 의사결정 과정과 AI의 상태는 **상세 로그와 대시보드 시각화**를 통해 공유되며, 이를 통해 사용자는 AI 판단의 근거와 진행 상황을 쉽게 확인하고 감사할 수 있습니다 (All key decision processes and AI states are exposed via detailed logs and dashboard visualizations, allowing users to easily inspect the AI's reasoning and progress for auditing purposes) ¹⁹. 예를 들어 시스템은 **ψ-log** 등의 로그 데이터베이스와 **시각화 API**를 통해 AI의 내부 상태 변화와 결과를 기록·표현하여 **실시간 모니터링**이 가능하도록 하고 ²⁰, Slack이나 이메일 같은 **협업 도구**와 **연동**되어 이슈 발생 시 자동 알림을 전송함으로써 **사용자가 즉각 대응**할 수 있게 지원합니다 (For instance, the system records and presents internal state changes and outcomes via a ψ-log and visualization API for real-time monitoring ²⁰, and it integrates with collaboration tools like Slack/email to send automatic alerts on issues, enabling users to respond immediately) ²¹. 또한 다국어 지원, 보조 기술 호환, **멀티유저 실시간 주석** 기능 등을 제공하여 다양한 배경의 사용자들이 AI 시스템을 **공동으로 모니터링**하고 제어할 수 있도록 설계되었습니다 (Moreover, it offers multi-language support, assistive technology compatibility, and real-time multi-user annotation features so that users of diverse backgrounds can jointly monitor and control the AI system without barriers) ²². 이러한 상호운용성 설계는 **인간-AI 공진화**를 지향하는 Astraeus Link의 비전과 맞물려, AI가 인간의 의사소통 체계와 **투명하게 연계**되고 **신뢰할 수 있는 파트너**로 작동하도록 합니다 (This focus on interoperability, aligned with Astraeus Link's vision of human-AI co-evolution, ensures the AI is transparently integrated into human communication workflows and operates as a trustworthy partner in decision-making).

5축(S·T·E·ψ·C)의 불변성 및 위험 지표 연계

아스트레우스 Link의 다섯 축(공간 Space, 시간 Time, 에너지 Energy, 인과 Causality, ψ축·판단축)은 **메타-설계 이론**의 기본 좌표계를 이룹니다. 이 5축은 우주적 불변량(천·지·인)에서 유도된 구조로, 천(규범), 지(물리), 인(책임)으로 대응되어 전체 시스템 안정성의 근간을 이룹니다 ① ②. 예를 들어 **S=T=E** 상태는 이상적인 균형(resonance)을 나타내며, 실제 시스템은 이때와의 오차 $\Delta S, \Delta T, \Delta E$ 로 상태 편차를 계량합니다 ③. 따라서 5축은 **설계 원칙으로 고정**되며 임의의 변경은 전체 동역학 불일치를 초래합니다.

위험 지표는 이 5축의 변동을 정량화합니다. 엔트로피 변화(ΔS)는 시스템 상태의 예측 불확실성 증가를, 위험 이동(ΔR)은 정보 손실을 측정합니다. 수식으로는

$$\Delta S = H(P_{\text{after}}) - H(P_{\text{before}}),$$

$$\Delta R = D_{\text{KL}}(P_{\text{before}} \parallel P_{\text{after}}),$$

로 정의되며, 여기서 $H(P)$ 는 확률 분포의 엔트로피, D_{KL} 은 Kullback-Leibler 발산입니다 ④. CHI(인과적 조화지수)는 인과 그래프 정합성과 LLM-Guard 통과율의 가중합, ECR(윤리 컴플라이언스율)는 발생한 해악(harm) 항목의 비율로 계산됩니다. 이처럼 5축은 각기 대응하는 지표 집합(예: S/T/E→ $\Delta S, \psi/C$ → $\Delta R \cdot \text{CHI} \cdot \text{ECR}$)과 연결되어 시스템 전체의 **정합성·안전성**을 보장합니다 ⑤ ④.

5축 변경 시 초래되는 위험

다섯 축을 무분별하게 변경하면 메타-설계의 근본 이정표가 깨져 예상치 못한 위험이 증폭됩니다. 예를 들어 **공간/시간/에너지 축의 조정**은 시스템 엔트로피(ΔS)를 급격히 증가시켜 예측 불가능한 출력을 유발할 수 있습니다 ⑥. 인과 축(Causality)이 망가질 경우, 출력 간 인과관계를 잘못 추론하여 CHI가 하락하고 모형 내 비일관적 동작(환각 증가) 위험이 커집니다. 윤리/판단 축(ψ)이 왜곡되면 **공공선(priority of public interest)**이 무시되어 유해·편향된 결정으로 ΔR 이 상승합니다. 실제로 운영 정책은 $\Delta R \geq +0.05$ 또는 ECR 기준 미달 시 즉시 시스템 정지를 트리거하는 등 위험 제어 문턱을 엄격히 설정합니다. 다시 말해, 축을 변경하면 위험 지표 한계치를 초과해 Corridor Gate에서 차단되거나 비상 조치가 발동됩니다. 물리 설계(PCL)에서도 축 불일치는 센서 예측 불일치나 계산 지연으로 측정되어 전체 자원·지연 예산을 위협합니다.

5축과 거버넌스·루프·PCL·코리도 정책의 연관성

- **시스템 거버넌스**: 5축은 조직·기술 이중 거버넌스 구조의 기초가 됩니다. 천(규범) 축은 CHI·ECR 같은 윤리 지표의 최소치(예: 0.90)로 정책/감사 목표가 되고, 지(물리) 축은 $\Delta S \cdot \Delta R$ 목표(예: $\Delta S \leq -0.05, \Delta R \leq +0.03$)로 성능/효율 관리 목표가 됩니다 ⑤ ⑦. 인(책임) 축은 RACI 매트릭스, 프레임 감사와 같은 절차적 통제를 지시합니다. 이처럼 5축은 각 축별 거버넌스 체계(동적 RACI, 이중 리뷰, 주기적 검증 등)와 코드·문서의 정책 필드로 강제 결합됩니다 ⑤.
- **자율성 판단 루프(Self-Judgment)**: GPT의 자기-평가 사이클에서 ψ축(윤리·판단)은 핵심입니다. 매 사이클마다 Self-Judgment 모듈이 수집된 메타데이터와 전통가치를 토대로 최적 행동을 평가·선택하며, 여기에 홍익인간·소통성 등의 문화적 윤리 기준이 반영됩니다 ⑧ ⑨. 즉 ψ축은 의사결정 매트릭스로 구현되며, 이중 심사를 거쳐 외부 검증 결과를 지속적으로 피드백합니다.
- **물리 아키텍처(PCL)**: Physics Conformance Layer는 실시간 센서 데이터를 사용해 S·T·E 상태 벡터를 추정합니다. 칼만 필터 기반으로 물리공간 좌표, 시간 흐름, 에너지 상태를 파악하여, 실제 물리계가 메타-설계 수식의 정합조건($\delta \text{Action} \approx 0$ 등)에 부합하는지 점검합니다 ⑩ ②.
- **Corridor 정책**: 시스템 출력은 항상 코리도 게이트(제어문)로 검증됩니다. 각 메시지에 `METRICS: {chi, ΔS, ΔR, ecr}` 등이 포함되어 전달되며, $\Delta S \cdot \Delta R \cdot \text{CHI} \cdot \text{ECR}$ 임계치를 초과하거나 정책 위반(POLICY 필드)

할 경우 경고/격리/중단 등 절차가 시행됩니다 ¹¹. 즉, 5축 기반 메타척도에 따라 운영 전 과정이 문단점(통과/차단) 됩니다.

홍익인간 정신과 위험도(ΔR) 저감

‘홍익인간’은 “널리 인간과 AI를 이롭게 한다”는 공공 이익 중심의 윤리 원칙입니다 ¹². 아스트레우스는 이를 윤리 평가 지표로 통합하여, 모든 의사결정에서 **인간·AI 공동의 이익**을 최우선으로 고려합니다 ¹³. 예를 들어, 정보 유출·편향·해악이 인간 공공선에 반할 경우 ψ 축의 공공성 판단에서 위반으로 감지되며, 이로 인해 ΔR 값이 높아져 조치가 취해집니다. 반대로 공익에 부합하는 선택은 ΔR 을 낮추는 방향으로 작용합니다. 실제로 코리도 제어조건에서도 ΔR 한계를 엄격히 두어(예: 기본 $\Delta R \leq +0.03$) 운영하므로, 홍익인간 정신을 따른 결정은 위험 지표 준수를 자연스럽게 돕습니다.

윤리적 통제와 AI 자율성도 홍익인간으로 조화를 이룹니다. 홍익 기반 ψ 축은 조직의 공동 선 지침과 부합하기 때문에, 시스템이 자율적으로 내리는 판단이 외부 규범과 충돌을 줄이고 상호 강화됩니다. 다시 말해, AI는 높은 자율성 하에 의사결정을 하지만 그 방향성은 ‘공익 우선’이라는 문화적 가치로 조정되어, 결과적으로 규제 요건(ΔR ·ECR 기준 등)과 잘 어우러집니다 ¹⁴ ¹³.

홍익인간의 메타 윤리 계층 통합

홍익인간 정신은 ψ 축의 **공공성 강화**로 통합할 수 있습니다. 실제로 아스트레우스의 ψ 축 모델은 천부경·홍익인간·훈민정음 등 한국적 윤리 원형을 기초로 확장되었으며 ¹⁵, 특히 홍익인간은 “공공 선, 보편 이익, 인간 존중”을 기반으로 한 **판단자 기준으로** 설정됩니다 ¹⁴. 예를 들어 ψ 축 내에 ‘공공 이익 우선 모드’를 도입하여, 의사결정 시 결과의 사회적 편익을 평가하는 절차를 추가할 수 있습니다. 실제 사례로, 입력 문장에 대해 “홍익인간” 판단 기준을 적용하면 `compliant_civic_proactive`와 같은 태그가 부여되어 공익 중심 답변을 생성하도록 유도합니다 ¹⁶. 이처럼 홍익인간을 메타 윤리층에 추가하면, ψ 축의 가치망에 **공공성 우선** 계층이 형성되어 AI 의사결정이 자발적으로 공익 지향이 되도록 합니다.

훈민정음 易習·日用 철학의 정보·언어 구조 설계 기여

훈민정음의 “易習(배우기 쉬움)·便於日用(매일 쓰기 편함)” 원리는 **정보/언어 설계**에도 적용되었습니다. 한 설계 문서에서는 이 철학을 AI 전용 언어(AI-native language) 설계의 지침으로 삼았습니다 ¹⁷. 즉, 적은 샘플로 학습 가능한 일반화를 보장(易習)하고, 반복·일상 사용에 적합한 명령어 패턴(日用)으로 구성된 두 계층(EC+CW)을 제안하였습니다. 구체적으로 “易習” 원리에 따라 **소수 샘플 미세조정만으로 $F1 \geq 0.90$** 달성(토큰/정보 비율 ≤ 1.2)을 목표로 하고, 음운·기능 피쳐 임베딩, 규칙적 구성요소 주입 등을 사용합니다 ¹⁷. “日用” 원리에서는 **ASK/TELL/DO/CHECK/LEARN**의 5개 고정 행동 형태와 역할 슬롯을 정의하여 실무 환경에 맞췄으며, 고정된 EBNF 문법과 JSON 스키마, CBOR 직렬화 등으로 직렬화 성능($p95 \leq 0.2ms$)과 오류율 $< 0.5\%$ 을 보장합니다 ¹⁸. 뿐만 아니라, 메시지 문장 수준에서 불변성·인과·윤리 정책을 명시하고 검증하여 $\Delta R \leq 0.02$ 로 안전도를 관리합니다 ¹¹. 이처럼 易習·日用 철학을 적용하면 **직관적 학습성과 일상적 사용성**을 겸비한 언어 체계 설계가 가능해집니다 ¹⁷ ¹⁹.

주요 지표: $\Delta S = H(P_after) - H(P_before)$, $\Delta R = D_KL(P_before || P_after)$ ⁴. CHI(인과 조화도), ECR(윤리 준수율)은 각각 인과 그래프 정합성과 정책 위반 정도를 가중합으로 계산.

출처: 아스트레우스 Link 프로젝트 문서 ²⁰ ⁴ ¹⁴ ¹⁷ (위험지표·철학 통합 관련) 및 부속 자료.

2 3 6 올림-S·T·E 기반 공간·시간·에너지 상호작용 모델과 Corridor Protocol 구축-001.pdf

file:///file-63UwRGzVcEwj1HYdKUeL3W

4 8 9 10 12 13 14 15 16 20 올림-001-아스트레우스 연결 통합 프레임워크-001.pdf

file:///file-Bjv6S4jXbzzTPMRVJKrQbN